

NER em português com modelos compactos: Um estudo com arquiteturas leves para desempenho eficiente

Filipe de Medeiros Santos¹

¹filipe.medeiros@academico.ufpb.com

Universidade Federal da Paraíba
Centro de Informática

26 de novembro de 2025

Este relatório apresenta um estudo sistemático sobre a tarefa de Reconhecimento de Entidades Nomeadas (NER) em textos em português, com foco em avaliar a eficiência de modelos compactos em comparação com Grandes Modelos de Linguagem (LLMs). Embora LLMs modernos — como GPT-4, GPT-5, Gemini ou DeepSeek — obtenham resultados altamente precisos em NER, seu uso impõe custos computacionais elevados, depende de infraestrutura especializada para inferência e frequentemente apresenta latências incompatíveis com aplicações de larga escala ou ambientes com recursos limitados.

Introdução

O Reconhecimento de Entidades Nomeadas (Named Entity Recognition — NER) é uma das tarefas fundamentais do Processamento de Linguagem Natural (PLN), servindo como base para sistemas de extração de informação e motores de busca. Com a popularização dos Grandes Modelos de Linguagem (LLMs), o desempenho em tarefas de NER atingiu níveis sem precedentes. Modelos como *GPT-4*, *GPT-5*, *Gemini* e *DeepSeek* demonstram grande capacidade de compreender contexto, desambiguar entidades e generalizar para domínios variados.

Entretanto, esses modelos apresentam um desafio importante: o número de parâmetros e a infraestrutura necessária para sua operação tornam a inferência cara, complexa e, muitas vezes, inviável para aplicações que exigem privacidade, latência controlada ou execução local. Para referência:

- **GPT-4 / GPT-5:** estão na faixa de centenas de bilhões a trilhões de parâmetros;
- **Gemini (Google):** modelos acima de 1 trilhão de parâmetros nas variantes mais poderosas;
- **DeepSeek-V3:** 371 bilhões de parâmetros;
- **DeepSeek-R1:** número de parâmetros não divulgado, embora seja estimado como maior que as versões base.

Em contraste, diversos modelos substancialmente menores têm mostrado capacidade de alcançar excelente desempenho em NER. Arquiteturas de LLM como *BERT-base* (110M parâmetros), *BERT-large* (340M) e modelos modernos compactos

como a família *Qwen-1.5-7B* (7B) oferecem uma alternativa prática, eficiente e acessível — muitas vezes com desempenho próximo, ou competitivo, quando adequadamente treinados em dados específicos do idioma.

Neste contexto, este projeto busca demonstrar que, para a tarefa de NER em português, não é necessário empregar LLMs massivos para alcançar resultados robustos e confiáveis. Em vez disso, mostramos experimentalmente que modelos compactos, bem ajustados e adequadamente treinados, podem ser suficientes para atingir desempenho de alto nível, com custo reduzido, inferência rápida e portabilidade, tornando sua adoção mais viável para aplicações reais.

Objetivos

Demonstrar que a tarefa de Reconhecimento de Entidades Nomeadas (NER) em português pode ser realizada com alto desempenho utilizando modelos compactos ou arquiteturas de Deep Learning especializadas, evidenciando que não é necessário recorrer a LLMs massivos e caros. Entre os objetivos específicos ressaltamos:

- Avaliar o desempenho de diferentes modelos compactos (como *BERT-base*, *BERT-large* e modelos de LLM na faixa de 7B parâmetros) aplicados à tarefa de NER.
- Comparar eficiência computacional entre modelos pequenos e LLMs de "pequeno" e "médio" porte.
- Explorar a influência dos conjuntos de dados disponíveis em português (como *WikiANN* e *LeNER-Br*) no desempenho das diferentes arquiteturas.
- Validar a capacidade de modelos menores de generalizar, mantendo precisão competitiva frente a LLMs.

Fundamentação Teórica

O Reconhecimento de Entidades Nomeadas é uma tarefa fundamental do Processamento de Linguagem Natural (PLN) que consiste em identificar e classificar automaticamente menções presentes em textos.

Nesta pesquisa, o foco é a identificação de três classes tradicionais amplamente utilizadas em aplicações reais: **PERSON**, **ORGANIZATION** e **LOCAL**. Essas categorias são essenciais em sistemas de extração de informação, recuperação de documentos e análise de notícias.

Historicamente, o NER evoluiu de abordagens baseadas em regras e expressões regulares para modelos estatísticos como Hidden Markov Models (HMMs) e Conditional Random Fields (CRFs). Contudo, com o avanço do Deep Learning modelos como *BiLSTM-CRF* tornaram-se um padrão ao combinar redes recorrentes bidirecionais, capazes de capturar informação contextual, com um CRF na camada de saída, responsável por modelar dependências estruturais entre os rótulos.

Com a introdução dos Transformers, o PLN passou por uma mudança paradigmática, permitindo o aprendizado de relações de longo alcance entre tokens sem dependência sequencial. Neste contexto, modelos pré-treinados em grandes corpora multilíngues ou monolíngues, como o *BERT*, fornece representações contextuais poderosas, que podem ser adaptadas a tarefas específicas por meio de *fine-tuning*. Neste trabalho, serão exploradas técnicas de ajuste fino com **restrição do número de parâmetros treináveis**, utilizando estratégias como *layer freezing* para reduzir custo computacional e evitar sobreajuste quando a quantidade de dados é limitada.

Além disso, o estudo investiga modelos treinados do zero (como as arquiteturas baseadas em *BiLSTM* e Transformers compactos), aprofundando conceitos fundamentais de Deep Learning, incluindo inicialização de pesos, otimização por gradiente, funções de perda para rotulagem sequencial e regularização. Essas técnicas formam o alicerce dos modelos compactos que serão comparados aos modelos pré-treinados de maior porte.

Com o surgimento dos LLMs, como os representantes da família GPT, Gemini ou DeepSeek, tornou-se possível executar NER sem qualquer ajuste fino, apenas por meio de instruções textuais — prática conhecida como **engenharia de prompts**. Em modelos grandes, a capacidade de seguir instruções permite realizar NER de forma *few-shot*, na qual alguns exemplos são incluídos no próprio prompt para demonstrar ao modelo o formato esperado da tarefa antes da predição final. Neste estudo, a engenharia de prompts será aplicada a um modelo de **7B parâmetros**, explorando como sua capacidade se compara ao desempenho de modelos compactos.

Metodologia

Esta seção descreve os conjuntos de dados utilizados para o treinamento e avaliação, bem como os modelos empregados na comparação experimental. O objetivo é estabelecer uma base clara para os experimentos conduzidos, garantindo reprodutibilidade e transparência na análise dos resultados.

Conjuntos de Dados

Para a realização da tarefa de Reconhecimento de Entidades Nomeadas (NER) em português, com foco nas classes **PERSON**, **ORGANIZATION** e **LOCAL**, foram utilizados dois datasets amplamente conhecidos e disponibilizados publicamente:

- **WikiANN (Português):** Conjunto de dados multilíngue com anotações automáticas.
- **LeNER-Br:** Dataset em português brasileiro composto principalmente por textos jornalísticos e anotações manuais de alta qualidade. O conjunto apresenta textos mais longos e ricos semanticamente. Por ter anotações humanas, serve como referência mais precisa para avaliação e ajuste fino de modelos.

Além dos conjuntos de dados acima, foram utilizados **10 textos adicionais**, não pertencentes a nenhum dos datasets, com o objetivo de avaliar a **capacidade de generalização** dos modelos em cenários completamente fora do domínio de treinamento. Os textos utilizados foram:

Textos utilizados para avaliação de generalização

1. João encontrou Maria ontem à noite.
2. Estou indo para João Pessoa amanhã cedo.
3. A Google lançou um novo modelo de IA.
4. A Universidade Federal da Paraíba convidou Ana Beatriz para apresentar sua pesquisa em São Paulo.
5. O presidente da Microsoft Brasil, André Oliveira, visitou o escritório em Fortaleza para anunciar novas parcerias.
6. Mariana trabalhou três anos na IBM, antes de se mudar para o Rio de Janeiro para atuar no BNDES.
7. Em 2024, Carlos Eduardo foi contratado pelo Banco do Brasil após concluir seu mestrado na USP, em São Paulo.
8. A Meta divulgou um relatório em que Sheryl Sandberg mencionou iniciativas de segurança digital nas operações da empresa.
9. Durante a reunião em Brasília, representantes da ONU e do Ministério da Justiça discutiram estratégias para reduzir crimes cibernéticos.
10. Pedro Henrique trabalhou por cinco anos na Petrobras no Rio de Janeiro, até receber uma proposta da Amazon em Seattle.

Modelos Utilizados

Para comparar abordagens distintas, foram selecionados três paradigmas complementares: modelos de *deep learning* compactos **treinados do zero**, modelos de LLMs pré-treinados especializados via *fine-tuning* e LLMs de "médio porte" utilizados por meio de **engenharia de prompts**.

Foram utilizadas arquiteturas clássicas para NER, compostas por embeddings, camadas bidirecionais LSTM, transformers e CRF para modelagem das transições de rótulos. Esses modelos são treinados do zero neste trabalho, permitindo avaliar sua eficiência e capacidade de generalização. A seguir descrevem-se as quatro arquiteturas presentes no arquivo `1_bilstm_base.ipynb`:

- **BiLSTM Base** com **5.040.903** parâmetros;
- **BiLSTM Medium** com **10.531.591** parâmetros;
- **BiLSTM Large + CRF** com **15.669.574** parâmetros;
- **Transformer treinado do zero** com **5.239.110** parâmetros.

Embora tenha menos parâmetros, o Transformer consome mais memória de GPU porque o mecanismo de *self-attention* exige armazenar matrizes de atenção completas para toda a sequência, o que cresce quadraticamente com o seu tamanho. As arquiteturas são demonstradas nas figuras a seguir:




Figura 1: Arquiteturas baseadas em BiLSTM.




Figura 2: Arquitetura Transformer treinada do zero.

Os modelos **BERT-base** e **BERT-large** são arquiteturas pré-treinadas amplamente utilizadas em tarefas de PLN e, neste trabalho, são empregados por meio de um *fine-tuning* controlado. Para reduzir o custo computacional e evitar sobreajuste, também aplicou-se a técnica de *layer freezing*, de forma que apenas uma fração dos parâmetros é atualizada durante o treinamento. Foram conduzidos os seguintes experimentos:

- **BERT Base + Camada Linear** (com **108.337.927** parâmetros): utiliza a arquitetura BERT Base com todos os parâmetros treináveis, adicionada uma camada linear para projeção dos estados ocultos nas classes de NER.
- **BERT Base + Camada Linear + CRF** (com **108.928.582** parâmetros): adicionada uma camada CRF (*Conditional Random Field*) ao final do modelo anterior. O CRF permite capturar dependências estruturais entre rótulos adjacentes, melhorando a coerência das sequências previstas.
- **BERT Large com layer freezing** (com **201.546.759** parâmetros): neste experimento dois terços das camadas superiores foi liberada para treinamento.
- **BERT Large** (com **333.353.991** parâmetros): aqui, todas as camadas do modelo foram liberadas para ajuste fino.




Figura 3: Arquitetura BERT base com camada linear e CRF.




Figura 4: Arquitetura BERT large.

Em contraste, o modelo **Qwen2.5** de porte "médio" com **7B parâmetros** é utilizado *sem* qualquer ajuste fino: emprega-se exclusivamente engenharia de prompts para orientar o modelo a realizar a tarefa de NER em regime few-shot.

Para isso, define-se um bloco de instruções sistemáticas que restringe rigorosamente o formato da saída, especifica o conjunto de rótulos permitidos e reforça regras de extração fiel ao texto. Além disso, dois exemplos completos — contendo texto, entidades anotadas e seus índices de caracteres — são fornecidos ao modelo como demonstrações explícitas do comportamento desejado.

Resultados

Foram conduzidos experimentos empíricos de *engenharia de prompt* para NER em português utilizando os modelos massivos **GPT-4**, **GPT-5**, **Gemini** e **DeepSeek**. Como esperado, esses LLMs de grande porte apresentaram **desempenho perfeito** na detecção e rotulagem das entidades. Dado que o objetivo deste trabalho é investigar principalmente modelos pequenos e médios, tais resultados — inteiramente corretos e sem variação — são **omitidos** por não contribuírem para a análise.

Qwen2.5

O maior modelo efetivamente trabalhado neste projeto foi o **Qwen2.5** com **7B parâmetros**. Embora seja um modelo grande, é aqui classificado como *médio porte* quando comparado aos LLMs massivos mencionados acima. Sua avaliação ocorreu exclusivamente por meio de *prompting* em regime *few-shot*, sem qualquer ajuste fino.

Os resultados indicaram que o modelo obteve **acurácia perfeita nas labels**, mas apresentou dificuldades na **ordenação dos tokens** no texto de saída, frequentemente deslocando as posições previstas. Para contornar esse problema, foi necessária uma etapa adicional de *matching* para localizar cada token previsto e corrigir sua posição final no documento anotado.

Exemplo da aplicação em textos utilizados para avaliação

Pedro Henrique

trabalhou por cinco anos na

Petrobras

no

Rio de Janeiro

, até receber uma proposta da

Amazon

em

Seattle

Em termos computacionais, a inferência do Qwen2.5-7B apresentou um tempo total de **2 minutos e 11 segundos** quando executado em uma **GPU NVIDIA T4**, equipada com **16 GB de VRAM** — um hardware de nuvem comumente utilizado para cargas de trabalho de inferência em larga escala. Apesar de funcional, esse tempo é consideravelmente mais alto que o dos modelos compactos considerados no restante deste trabalho.

Esse comportamento evidencia que, embora modelos de bilhões de parâmetros possam entregar precisão elevada mesmo sem *fine-tuning*, o custo computacional e algumas inconsistências estruturais na saída (como o desalinhamento de tokens) tornam seu uso menos prático.

Modelos de deep learning

Os experimentos com quatro arquiteturas de redes neurais para NER em português revelaram uma progressão clara no desempenho conforme aumentava a complexidade arquitetural:

Tabela 1: Métricas de Desempenho dos Modelos de DL

Modelo	F1-Score	Precisão	Revocação
BiLSTM Small	0,7492	0,7217	0,7790
BiLSTM Medium	0,8030	0,8027	0,8032
BiLSTM Large	0,8539	0,8626	0,8454
Transformer	0,8250	0,8258	0,8242




Figura 5: Acurácia dos modelos de DP.

O modelo **BiLSTM Large com CRF** apresentou o melhor desempenho geral entre as arquiteturas avaliadas. Ele alcançou uma precisão de 86,26%, refletindo uma notável capacidade de evitar falsos positivos, e uma revocação de 84,54%, indicando boa cobertura na identificação de entidades presentes no texto.

Esses resultados decorrem da combinação eficaz entre a habilidade do BiLSTM de capturar dependências contextuais em ambas as direções da sequência e a capacidade do CRF de impor coerência estrutural por meio da modelagem explícita das transições entre etiquetas. Embora sua acurácia global (92,61%) tenha sido ligeiramente inferior à observada em arquiteturas mais simples, esse comportamento é esperado, uma vez que o CRF prioriza a consistência sequencial em detrimento da precisão token a token.

Apesar do desempenho robusto, o modelo ainda apresenta desafios relacionados à capacidade de generalização. Observou-se dificuldade na identificação de entidades inseridas em contextos ambíguos, além de desempenho reduzido em domínios específicos que não estavam adequadamente representados no conjunto de treinamento, conforme a seguir:

Exemplo da aplicação em textos utilizados para avaliação

A Google lançou um novo

modelo de IA

LLMs *fine tuning*

Para avaliar o impacto de diferentes arquiteturas e estratégias de *fine-tuning* no desempenho do NER em português, foram implementadas e comparadas quatro variações de modelos baseados no BERT. Os resultados demonstram que otimizações na camada de classificação podem ser mais eficazes que simplesmente aumentar a capacidade do modelo.

Tabela 2: Desempenho comparativo dos modelos BERT

Modelo	Acurácia	Precisão	Revocação
BERT Base	0.9634	0.9241	0.9310
BERT Base + CRF	0.9962	0.9136	0.9241
BERT Large (2/3)	0.9667	0.9293	0.9367
BERT Large (100%)	0.9654	0.9257	0.9351

Os experimentos revelaram insights importantes sobre a eficácia das diferentes abordagens. O modelo **BERT Base com camada CRF** apresentou a maior acurácia (99,62%) e, mesmo adicionando apenas um pequeno número de parâmetros em relação à versão sem CRF, superou o desempenho do **BERT Large**, que possui aproximadamente três vezes mais parâmetros. Esse resultado sugere que a estrutura de dependências introduzida pelo CRF pode trazer ganhos mais significativos do que simplesmente aumentar a capacidade do modelo.

O **BERT Large com apenas parte dos parâmetros treináveis** alcançou o melhor f-1 de 93,29%, demonstrando que uma estratégia de *fine-tuning* mais conservadora pode ser mais eficaz em modelos maiores. Por outro lado, o **BERT Large com todos os parâmetros liberados para treinamento** apresentou desempenho inferior à versão parcial, sugerindo possível *overfitting* ou dificuldades de otimização.

Na avaliação qualitativa com 10 textos de benchmark, todos os modelos exibiram comportamentos idênticos, com duas falhas recorrentes: a sigla **BNDES** foi sempre segmentada em tokens individuais (“B”, “N”, “D”, “E”, “S”), levando o modelo a classificá-los incorretamente como organizações distintas; e o nome **Sheryl Sandberg** foi tokenizado como “Sher” e “yl Sandberg”, resultando em entidades fragmentadas. Essas falhas refletem limitações do tokenizador do BERTimbau, que apresenta dificuldades com siglas pouco frequentes e nomes próprios em inglês ausentes do vocabulário de pré-treinamento.

Considerações Finais

Os resultados obtidos nesta seção revelam contrastes importantes entre modelos de diferentes portes e estratégias de treinamento. Em primeiro lugar, os **LLMs massivos** (GPT-4, GPT-5, Gemini e DeepSeek) apresentaram **desempenho perfeito** no reconhecimento de entidades, mas seu custo computacional elevado torna seu uso pouco viável para aplicações rotineiras.

Por outro lado, os **LLMs de médio porte**, representados aqui pelo Qwen2.5-7B, mostraram excelente desempenho em termos de precisão das etiquetas, mas ainda assim apresentaram sérios desafios. Apesar da alta qualidade sem *fine-tuning*, o modelo demonstrou **ineficiência computacional**, além de **problemas sistemáticos de desalinhamento de tokens**, exigindo passos adicionais de correção. Em contraste, modelos menores ajustados por *fine-tuning* foram capazes de superar esse problema com grande eficácia, produzindo saídas muito mais estruturadas e alinhadas com os requisitos da tarefa.

Os **modelos de deep learning tradicionais**, baseados em BiLSTM e Transformer treinados do zero, embora tenham apresentado evolução consistente conforme a complexidade arquitetural aumentou, ainda ficaram aquém do desempenho observado nos modelos baseados em LLMs. Mesmo o BiLSTM Large, que obteve os melhores resultados desse grupo, apresentou limitações de generalização, especialmente em contextos ambíguos ou pouco representados no treinamento.

Por fim, os **modelos baseados em BERT com ajuste fino** mostraram-se a solução mais equilibrada entre custo computacional e desempenho. O BERT Base com CRF alcançou a maior acurácia entre todos os modelos treinados localmente, demonstrando que pequenas modificações estruturais podem gerar ganhos superiores ao mero aumento de parâmetros. Já o BERT Large com *fine-tuning* parcial obteve o melhor F1 (93,29%), evidenciando que estratégias de ajuste seletivo são mais eficazes do que o treinamento completo do modelo. Esses modelos se destacaram por:

- oferecerem **excelente desempenho** com custo computacional baixo;
- produzirem **saídas mais consistentes e bem alinhadas** do que LLMs médios sem *fine-tuning*;
- permitirem ciclos rápidos de experimentação e ajuste;
- apresentarem **generalização satisfatória** mesmo com dados limitados de treinamento.

Em síntese, os experimentos indicam que modelos compactos e bem ajustados podem atingir níveis de desempenho muito competitivos, representando uma alternativa eficiente e economicamente viável aos LLMs de médio e grande porte.

Pesquisas Futuras

Os resultados desta pesquisa apontam para duas frentes promissoras de investigação. A primeira consiste em aprofundar o estudo de **modelos extremamente compactos**, com aproximadamente 10 milhões de parâmetros ou menos, buscando alcançar boa capacidade de generalização mesmo com arquiteturas altamente reduzidas.

A segunda linha de pesquisa visa **reforçar a generalização dos modelos baseados em BERT**, explorando diferentes cabeças de classificação treinadas em conjunto e ampliando significativamente o conjunto de dados de treinamento. Isso inclui ir além do WikiANN e do LeNER-Br, incorporando domínios especializados, textos jornalísticos recentes e corpora anotados manualmente, de modo a capturar maior diversidade linguística e contextual.

Em conjunto, essas direções têm potencial para produzir modelos mais leves, mais robustos e com maior aplicabilidade prática no reconhecimento de entidades nomeadas em português.

Referências

- [1] S. Raaijmakers, *Deep Learning for Natural Language Processing*. Manning Publications, 2022.
- [2] H. Lane, C. Howard, H. Hapke, *Natural Language Processing in Action: Understanding, Analyzing, and Generating Text with Python*. Manning Publications, 2019.
- [3] S. Bird, E. Klein, E. Loper, *Natural Language Processing with Python*. O'Reilly Media, 2009.
- [4] L. Tunstall, L. von Werra, T. Wolf, *Natural Language Processing with Transformers: Building Language Applications with Hugging Face*. O'Reilly Media, 2022.